

Laboratorio # 1

Preparación de un corpus y EDA

Natural Language Processing

Cynthia Santos - 20230493

Introducción

En este laboratorio se trabajó con el corpus Spanish News Classification, un conjunto de noticias reales en español organizadas por categoría temática. El objetivo fue explorar el corpus, aplicar un pipeline de normalización y realizar un Análisis Exploratorio de Datos (EDA) para entender su estructura y su comportamiento antes de usarlo en tareas de NLP.

El trabajo se desarrolló en Python, siguiendo el notebook adjunto, y se apoyó en librerías como pandas, NLTK, spaCy, matplotlib y wordcloud.

1. Exploración inicial del corpus

La primera revisión del archivo permitió responder las preguntas básicas del laboratorio:

Aspecto	Resultado
Documentos	1,217
Columnas	url, news, Type
Información por columna	url: enlace de la noticia; news: texto completo; Type: categoría temática
Categorías	7
Filas vacías	0
Filas duplicadas	75
Categoría más grande	Macroeconomía (340)
Categoría más pequeña	Reputación (26)

Interpretación. No se encontraron valores vacíos, pero sí duplicados, por lo que el corpus no está completamente limpio. Además, la distribución está desbalanceada: Macroeconomía domina claramente, mientras que Reputación tiene pocos documentos. Eso es importante porque puede influir en un modelo de clasificación.

2. Preparación del corpus

Se aplicó el pipeline visto en clase en este orden: tokenización, minúsculas, eliminación de puntuación, eliminación de stopwords y lematización. La siguiente tabla resume el efecto de cada paso sobre el vocabulario.

PASO	TOKENS	TIPOS	REDUCCIÓN VOCABULARIO TOKENIZACIÓN	DE VS.
TOKENIZACIÓN	684,297	32,606	0.00%	
MINÚSCULAS	684,297	29,571	9.31%	
ELIMINAR PUNTUACIÓN	637,564	29,530	9.43%	
ELIMINAR STOPWORDS	339,170	29,315	10.09%	
LEMATIZACIÓN	339,206	22,398	31.31%	

Resultado clave. El vocabulario se redujo de 32,606 a 22,398 tipos, una disminución total de 31.31%. En este corpus, la lematización fue el paso con mayor impacto, porque unificó distintas formas de una misma palabra.

3. ¿Qué es un EDA?

EDA significa Exploratory Data Analysis o Análisis Exploratorio de Datos. Es la fase inicial de un proyecto de ciencia de datos en la que se estudia la estructura del conjunto de datos, su calidad y su comportamiento general antes de construir modelos.

Su objetivo es detectar vacíos, duplicados, valores atípicos y patrones útiles; además, ayuda a decidir qué limpieza, transformación o visualización conviene aplicar. En NLP, el EDA también sirve para analizar vocabulario, longitud de documentos, frecuencia de palabras y distribución por categorías.

4. Resultados del EDA sobre el corpus preparado

Tras la normalización, el corpus quedó con 339,206 tokens y 22,398 tipos, lo que da una riqueza léxica global (type/token ratio) de 0.066. Esto indica que, aunque el corpus tiene mucho texto, el vocabulario repetido es alto, algo esperable en noticias del mismo dominio.

La tabla de frecuencias mostró que las palabras más repetidas están fuertemente ligadas a la temática económica y empresarial del corpus: poder, bbva, año, banco, país, empresa e inflación aparecen entre las primeras posiciones.

El histograma de longitud de documentos mostró una distribución asimétrica: la mayoría de las noticias tiene una longitud intermedia y unas pocas son mucho más largas. Esta forma es normal en corpus reales de noticias.

La curva de Zipf en escala log-log siguió una tendencia descendente cercana a la esperada. La pendiente aproximada fue -1.374, lo que confirma el comportamiento típico de un lenguaje natural, aunque con desviaciones provocadas por nombres propios, instituciones y términos muy repetidos del dominio financiero.

Riqueza léxica por categoría. La categoría Reputacion tiene la mayor riqueza relativa, mientras que Macroeconomía presenta la menor, coherente con su tamaño y con el mayor nivel de repetición temática.

Categoría	Tokens	Tipos	Type/Token
<i>Reputacion</i>	7,815	2,537	0.3246
<i>Regulaciones</i>	37,783	7,026	0.1860
<i>Alianzas</i>	49,927	8,666	0.1736
<i>Otra</i>	29,092	4,974	0.1710
<i>Sostenibilidad</i>	57,540	8,052	0.1399
<i>Innovacion</i>	61,183	6,871	0.1123
<i>Macroeconomia</i>	95,866	9,421	0.0983

5. Comparación por categoría

Comparando dos categorías, se observa que el vocabulario cambia claramente según el tema:

Innovación	Macroeconomía	Comentario
<i>bbva, poder, banco, cliente, digital</i>	inflación, precio, año, tasa, aumento	Innovación se orienta a tecnología y cliente; Macroeconomía gira alrededor de variables económicas. En una predominan términos de transformación digital, en la otra aparecen indicadores macro y mercado.
<i>dato, permitir, financiero</i>	país, mes, mayor, mercado	

Nube de palabras. La nube de palabras refleja visualmente el peso de los términos dominantes y confirma que el corpus está centrado en banca, economía, empresa e innovación.

6. Análisis final

¿La curva de Zipf se parece a la teórica?

- Sí. La forma general es muy parecida a la ley de Zipf: pocas palabras muy frecuentes y muchas palabras poco frecuentes. Las diferencias se explican por la especialización temática del corpus y por la presencia de nombres propios y términos financieros repetidos.

¿Cuánto se redujo el vocabulario y qué paso impactó más?

- La reducción total fue de 31.31%. El mayor impacto ocurrió con la lematización, porque agrupa variantes morfológicas bajo una misma forma. La eliminación de puntuación y el paso a minúsculas tuvieron un efecto menor.

¿Quitar stopwords afectó el significado?

- En general no afectó el contenido principal de las noticias, pero siempre existe el riesgo de perder matices en algunas frases. Aun así, para este corpus la limpieza ayuda más de lo que perjudica, porque la señal temática sigue clara.

¿Qué desafíos del español se encontraron?

- Principalmente la flexión verbal, los cambios de género y número, las tildes, los nombres propios y los términos compuestos. Todo eso aumenta la variación superficial del vocabulario y justifica usar lematización.

¿Normalizaría igual un modelo de lenguaje?

- No exactamente. Para un modelo clásico de NLP sí conviene una normalización fuerte, pero para modelos modernos como Transformers conviene conservar más información contextual. En ese caso, eliminar demasiada puntuación o cambiar en exceso el texto puede quitar señales útiles.

Conclusión

El laboratorio permitió explorar, depurar y analizar un corpus real de noticias en español, lo que hizo posible comprender mejor cómo se comporta un conjunto de datos textuales antes de ser utilizado en tareas de NLP. A través del proceso de normalización se pudo observar el efecto de cada paso sobre la cantidad de tokens y el tamaño del vocabulario, evidenciando una reducción significativa en la variedad léxica y una mayor uniformidad en el texto.

Además, el análisis exploratorio mostró patrones característicos del lenguaje natural, como la distribución desigual de las palabras y un comportamiento coherente con la ley de Zipf. Esto confirma que, incluso después de la limpieza, el corpus conserva la estructura lingüística necesaria para su estudio.

Por otra parte, la comparación entre categorías permitió identificar que cada tema mantiene un vocabulario propio, con términos representativos según la temática de las noticias. Este hallazgo es especialmente útil para futuras tareas de clasificación automática, ya que demuestra que el corpus contiene suficiente información discriminativa para diferenciar entre categorías.

Link del Repositorio

- <https://github.com/Cynthiss/NLP>