

Laboratorio 2 - Representaciones básicas de texto

Natural Language Processing

Cynthia Santos - 20230493

1. Introducción

Este laboratorio continúa directamente el análisis del corpus trabajado en el Laboratorio 1. A partir del texto ya normalizado y lematizado, se construyen representaciones numéricas que permiten comparar documentos, medir similitud y observar qué tan informativas son distintas técnicas de vectorización para noticias en español.

2. Resumen numérico de los resultados

Métrica	Resultado
BoW (documentos × vocabulario)	1217 × 21911
Dispersión BoW completa	99.14%
Dispersión con 100 / 500 / 1000 / 5000 términos	69.83% / 83.83% / 89.03% / 96.73%
Unigramas / Bigramas	21911 / 223876
Dispersión unigramas / bigramas	99.14% / 99.88%
TF-IDF	1217 × 21911
Similitud promedio misma / distinta categoría	0.0752 / 0.0401

3. Bag of Words y dispersion

La representación Bag of Words transforma cada documento en un vector de conteos. En esta forma, cada columna corresponde a una palabra del vocabulario y cada fila a una noticia. El resultado fue una matriz de tamaño 1217 × 21911, almacenada como matriz dispersa CSR.

Esta representación es útil porque convierte el texto en información numérica lista para modelos de aprendizaje automático. Sin embargo, también pierde tres rasgos importantes del lenguaje: el orden de las palabras, la gramática y el contexto. Dos documentos con el mismo conjunto de palabras, pero con distinto orden, pueden verse casi iguales para el modelo.

La dispersión total de la matriz fue de 99.14%, lo que significa que la gran mayoría de las celdas son ceros. Al limitar el vocabulario a 100, 500, 1000 y 5000 palabras más frecuentes, la dispersión aumentó de 69.83% a 83.83%, 89.03% y 96.73%, respectivamente. Esto ocurre porque cada documento usa solo una pequeña parte del vocabulario total; mientras más columnas se agregan, más celdas vacías aparecen.

Una matriz dispersa es aquella en la que predominan los valores cero. En estos casos conviene usar formatos especiales como CSR (Compressed Sparse Row), que almacenan solo los valores distintos de cero y su posición. Esto reduce considerablemente memoria y costo de cómputo frente a una matriz densa.

4. N-gramas

Al comparar unigramas con bigramas, el vocabulario pasó de 21911 a 223876 términos. La dispersión también aumentó, de 99.14% a 99.88%. Esto confirma que al introducir secuencias de dos palabras se incrementa de manera fuerte el espacio de características.

Entre los bigramas más frecuentes aparecieron expresiones como banco central, bbva research, tasa interés, cambio climático, entidad financiero, precio consumidor y punto básico. Estas combinaciones capturan contexto local que no se observa con unigramas por separado.

La ventaja de los bigramas es que preservan parte del orden y permiten representar expresiones más específicas; su costo es un vocabulario mucho mayor y una matriz todavía más dispersa. En consecuencia, n-gramas más grandes aportan contexto, pero también aumentan la dimensionalidad y el almacenamiento requerido.

5. TF-IDF

La matriz TF-IDF tuvo el mismo tamaño que BoW: 1217×21911 . Esta representación asigna más peso a los términos que son frecuentes dentro de un documento pero raros en el resto del corpus, y reduce la importancia de palabras muy repetidas en todas las noticias.

Para Macroeconomía (documento 3), los términos más relevantes fueron marzo, IPC, tasa, mensual, IPCA e interanual. En conteo simple, la lista incluyó tasa, marzo, IPC, punto, mensual, situar, precio, interanual, inflación y febrero. La coincidencia es parcial: TF-IDF conserva las palabras temáticamente importantes, pero cambia el orden cuando una palabra es más distintiva para el documento.

Para Innovación (documento 7), sobresalieron agile, nacho, podcast, alumno, introducir, legal, thinktank, RRHH y talentboost. En conteo simple, las palabras más repetidas fueron podcast, agile, nacho, varios, introducir, alumno, sector, legal, placer y entrevistar. En Sostenibilidad (documento 12), aparecieron agua, lluvia, escuela, scall, fundación, sostenible, litro, sistema y educativo, mientras que por conteo simple destacaron agua, bbva, sostenible, escuela, sistema, lluvia, comunidad, scall, fundación y poder. Esto muestra que TF-IDF penaliza términos muy comunes en el corpus, como BBVA, y privilegia vocabulario más representativo del artículo.

6. Similitud entre documentos

Usando similitud coseno sobre TF-IDF, el documento de referencia (índice 3, Macroeconomía) recuperó sus cinco vecinos más cercanos también dentro de Macroeconomía, con similitudes de 0.4044, 0.2860, 0.2370, 0.2334 y 0.2229. Esto sugiere que la representación TF-IDF sí agrupa razonablemente documentos temáticamente parecidos.

Los cinco documentos más similares al documento de referencia fueron:

Índice	Categoría	Similitud coseno
1211	Macroeconomía	0.404425
1204	Macroeconomía	0.285978
834	Macroeconomía	0.237040
121	Macroeconomía	0.233441
240	Macroeconomía	0.222911

La similitud promedio entre documentos de la misma categoría fue 0.0752, frente a 0.0401 entre categorías distintas. La diferencia no es enorme, pero sí consistente: los textos de una misma categoría tienden a compartir más vocabulario relevante.

Los pares de categorías con mayor similitud promedio fueron:

Categoría 1	Categoría 2	Similitud promedio
Otra	Innovación	0.058120
Innovación	Sostenibilidad	0.051267
Otra	Macroeconomía	0.049693
Otra	Sostenibilidad	0.049073
Otra	Reputación	0.044708

7. Análisis final

La dispersión crece al pasar de unigramas a bigramas porque el vocabulario aumenta mucho más rápido que la cantidad de palabras presentes en cada documento. Con más columnas, los ceros se multiplican; por eso la matriz de bigramas es más dispersa que la de unigramas. Si se añadieran trigramas, la dispersión crecería todavía más.

De las tres representaciones trabajadas, TF-IDF me parece la más adecuada para clasificar noticias por categoría. BoW es un buen punto de partida, pero trata todas las palabras con el mismo peso. Los n-gramas capturan más contexto, aunque incrementan demasiado la dimensionalidad. TF-IDF conserva la ventaja de una representación simple y, además, resalta términos discriminativos, por lo que suele ser más útil para separar categorías.

La similitud coseno agrupa razonablemente los documentos por categoría. En este corpus, la categoría de referencia recuperó cinco vecinos de su misma clase y la similitud promedio dentro de categoría fue mayor que entre categorías diferentes. Las mayores confusiones aparecen con la categoría Otra, especialmente con Innovación, Sostenibilidad y Macroeconomía. Esto es coherente con su carácter heterogéneo, ya que reúne noticias difíciles de clasificar en una sola temática.

Si tuviera que construir un buscador de noticias similares, elegiría TF-IDF combinado con similitud coseno. Esta opción equilibra eficiencia e interpretación: resalta términos informativos, ignora en parte palabras demasiado comunes y permite encontrar noticias relacionadas aunque no tengan la misma longitud. Por eso, para búsqueda semántica básica dentro de este corpus, TF-IDF es la mejor elección entre las tres representaciones.

Link del Repositorio

- <https://github.com/Cynthiss/NLP>