

Laboratorio 3

Análisis de resultados

Naive Bayes para clasificación de noticias

Cynthia Santos - 20230493

Resultados de referencia

Representación	Vocabulario	Accuracy val.	F1 macro val.
BoW completo	18,239	0.8142	0.7389
BoW 1,000	1,000	0.8197	0.8216
BoW 5,000	5,000	0.8197	0.8219
BoW 1-2 gramas	184,605	0.7432	0.6507
TF-IDF	18,239	0.5792	0.3751
BoW 5,000 · NB propio	5,000	0.8197	0.8219

Nota: estos resultados corresponden al conjunto de validación, que fue el utilizado para comparar configuraciones antes de tocar el conjunto de prueba.

1. ¿Por qué Naive Bayes es probabilístico y no basado en distancia o similitud? ¿Qué ventajas y limitaciones tiene frente a similitud coseno?

Naive Bayes es probabilístico porque asigna a cada clase una probabilidad previa $P(c)$ y estima la verosimilitud de observar las palabras del documento dada esa clase, $P(w|c)$. Para cada noticia combina esas evidencias y selecciona la categoría con el mayor puntaje posterior. En cambio, la similitud coseno del Laboratorio 2 no calcula la probabilidad de una clase: compara la orientación de dos vectores y devuelve qué tan parecidos son dos documentos.

La principal ventaja de Naive Bayes es que puede producir una clasificación directa incluso con matrices muy dispersas y con vocabularios grandes. Además, sus probabilidades por clase permiten interpretar qué términos aportan evidencia a favor de cada categoría. En este laboratorio, BoW con 5,000 términos alcanzó 0.8197 de accuracy y 0.8219 de F1 macro en validación. Como limitación, el modelo depende del supuesto de independencia condicional y no representa bien el contexto ni el orden de las palabras. La similitud coseno, por su parte, resulta muy útil para recuperar documentos parecidos y no requiere una clase predefinida, pero no es por sí sola un clasificador supervisado.

2. ¿Por qué funcionó razonablemente bien a pesar del supuesto de independencia?

Aunque las palabras de un idioma no son realmente independientes, Naive Bayes puede funcionar bien porque muchas palabras aportan señales débiles pero acumulables. Cuando una noticia contiene términos como “inflación”, “precio”, “tasa” y “crecimiento”, varias señales independientes aproximadas favorecen Macroeconomía y el puntaje de esa clase termina dominando a los demás.

Los resultados respaldan esta idea, incluso con la simplificación del modelo, BoW completo alcanzó 0.8142 de accuracy en validación y la mejor variante, BoW con 5,000 palabras, llegó a 0.8219 de F1 macro. Además, las matrices de conteo son muy dispersas, pero Naive Bayes trabaja de manera natural con ese tipo de datos. En lugar de necesitar una representación exacta de todas las relaciones entre palabras, le basta con que varias evidencias relevantes produzcan un puntaje total mayor que el de las otras clases. Por eso importa el orden relativo de los scores, la clase con el mayor puntaje no necesita modelar perfectamente el lenguaje necesita acumular más evidencia que las alternativas.

3. ¿Qué parte fue más difícil de implementar desde cero y qué se aprendió?

La parte más difícil fue combinar correctamente la verosimilitud $P(w|c)$, el suavizado de Laplace y los logaritmos. El suavizado es necesario para evitar probabilidades cero cuando un término no aparece en una categoría, los logaritmos permiten convertir el producto de muchas probabilidades pequeñas en una suma numéricamente estable.

La implementación propia permitió observar de forma explícita cómo se construye el puntaje de cada clase: $\log P(c)$ más la suma de las log-probabilidades de las palabras presentes. Esto hace visible algo que queda oculto al utilizar directamente MultinomialNB. La validación fue especialmente clara porque la implementación propia obtuvo 0.8197 de accuracy y 0.8219 de F1 macro, y sus predicciones coincidieron en 100% con las de MultinomialNB usando el mismo BoW de 5,000 palabras y el mismo suavizado.

4. ¿Qué categorías fueron más fáciles y cuáles más difíciles? ¿Coincide con el Laboratorio 2?

En la validación del modelo BoW completo, las categorías más fáciles fueron Macroeconomía ($F1 = 0.9038$), Innovación ($F1 = 0.8696$) y Sostenibilidad ($F1 = 0.8333$). Las más difíciles fueron Reputación ($F1 = 0.4000$), Otra ($F1 = 0.6875$) y Regulaciones ($F1 = 0.7317$). Reputación debe interpretarse con cautela porque solo tuvo cuatro documentos en validación.

Existe una coincidencia parcial con el Laboratorio 2. Allí los pares con mayor similitud promedio incluían Otra–Innovación (0.0581) e Innovación–Sostenibilidad (0.0513). En este laboratorio, una de las confusiones más frecuentes fue precisamente Otra, Innovación, con cinco errores. La otra confusión máxima fue Alianzas, Regulaciones, también con cinco errores. Por tanto, la similitud coseno ya había señalado algunos solapamientos temáticos que luego reaparecieron como errores de clasificación, aunque no todos los casos coinciden.

5. ¿Qué papel tuvieron validación y prueba y por qué no mezclarlas?

El conjunto de entrenamiento se utilizó para ajustar los vectorizadores y entrenar los modelos. El conjunto de validación se utilizó para comparar BoW, TF-IDF, vocabularios de 1,000 y 5,000 palabras, y la representación con unigramas más bigramas. Gracias a esta separación fue posible elegir la configuración de BoW con 5,000 términos usando datos que el modelo no vio durante el entrenamiento.

El conjunto de prueba debe mantenerse aislado hasta la evaluación final. No debe utilizarse para decidir qué representación o hiperparámetros son mejores, porque entonces el modelo y el proceso de desarrollo quedarían indirectamente adaptados a los datos de prueba. La separación permite que la evaluación final sea una estimación más honesta de la capacidad de generalización. En este laboratorio, la división fue 70% entrenamiento, 15% validación y 15% prueba, con estratificación por categoría.

6. ¿Qué riesgos habría en producción y cómo mitigarlos?

Un primer riesgo es la aparición de categorías nuevas que no existen en el entrenamiento, el clasificador necesariamente intentará asignarlas a una de las clases conocidas. Una mitigación sería incorporar una política de “desconocido” y revisar periódicamente noticias de baja confianza o con puntajes muy cercanos entre clases.

Otro riesgo es el cambio del vocabulario con el tiempo: pueden aparecer nombres de productos, empresas, términos tecnológicos o acontecimientos que no estaban presentes durante el entrenamiento. Esto puede reducir el desempeño a medida que cambia la distribución del lenguaje. Conviene monitorear el rendimiento, recolectar ejemplos recientes y reentrenar periódicamente el modelo.

También existe el desbalance de clases. Reputación tiene muy pocos documentos y mostró el peor desempeño por categoría. Para mitigarlo se puede aumentar la cantidad de ejemplos de clases minoritarias, revisar métricas macro además de accuracy y ponderar o ajustar el proceso de entrenamiento. Finalmente, también sería necesario vigilar cambios en las fuentes de noticias, errores de etiquetado y deriva de datos, manteniendo un conjunto de evaluación reciente e independiente.

Conclusión general

En conjunto, los resultados muestran que Naive Bayes funcionó mejor con una representación BoW compacta que con TF-IDF o con la combinación de unigramas y bigramas. La mejor configuración validada fue BoW con 5,000 palabras, con un F1 macro de 0.8219, y la implementación propia reprodujo exactamente las predicciones de scikit-learn. Esto sugiere que, para este corpus, conservar las señales de frecuencia más útiles y controlar el tamaño del vocabulario fue más beneficioso que incrementar la complejidad de la representación.

Link de repositorio :

- https://github.com/Cynthiss/NLP/tree/main/Lab_3