

LABORATORIO #4

MODELOS LINEALES

Reporte de resultados y análisis

Cynthia Santos - 20230493

1. Construcción de los modelos

Se reutilizaron las particiones estratificadas del Laboratorio #3: 851 documentos para entrenamiento, 183 para validación y 183 para prueba. También se reutilizaron los mismos vectorizadores ajustados solo con entrenamiento, con un vocabulario de 18,239 características para BoW y TF-IDF. Se entrenaron dos modelos de regresión logística multiclase, uno con cada representación.

Modelo	Vocabulario	Tiempo entrenamiento
Regresión logística + BoW	18,239	0.8765 s
Regresión logística + TF-IDF	18,239	0.3511 s

En regresión logística, cada documento se convierte en un vector x y el modelo calcula un puntaje $z = w \cdot x + b$. Los pesos indican cuánto empuja cada característica hacia una clase; en el problema multiclase se compara el puntaje/probabilidad de todas las categorías para seleccionar la predicción.

2. Entrenamiento y evaluación

En validación, BoW obtuvo mejor desempeño que TF-IDF con regresión logística. La brecha entre entrenamiento y validación también muestra indicios de sobreajuste, especialmente en BoW.

Modelo	Conjunto	Accuracy	F1 macro	F1 ponderado
RL + BoW	Entrenamiento	0.9965	0.9966	0.9965
RL + BoW	Validación	0.8470	0.8278	0.8440
RL + TF-IDF	Entrenamiento	0.9495	0.8957	0.9464
RL + TF-IDF	Validación	0.7869	0.6488	0.7688

Las matrices de confusión confirmaron que BoW mantuvo más aciertos en categorías como Macroeconomía, Innovación y Sostenibilidad. TF-IDF tuvo mayores dificultades en categorías pequeñas; en particular, Reputación tuvo recall 0.00 en validación con TF-IDF, frente a 0.75 con BoW.

Resultados finales sobre prueba

Modelo	Representación	Accuracy	F1 macro	F1 ponderado
Naive Bayes	BoW	0.8197	0.7435	0.8106
Naive Bayes	TF-IDF	0.6011	0.3797	0.5130
Regresión logística	BoW	0.8743	0.8517	0.8743
Regresión logística	TF-IDF	0.8852	0.7504	0.8756

3. Interpretación de pesos

El mejor modelo en validación fue Regresión Logística + BoW, por lo que se analizaron sus coeficientes. En Macroeconomía destacaron inflación, aumento y precio; en Innovación, BBVA, capital, innovación y tecnología; y en Sostenibilidad, sostenible, sostenibilidad, climático y verde. Los pesos negativos representan evidencia en contra de la clase.

La comparación con Naive Bayes mostró coincidencias, pero no rankings idénticos. Por ejemplo, inflación y precio aparecen como señales importantes para Macroeconomía en ambos enfoques. Sin embargo, Naive Bayes también da alta probabilidad a palabras más generales, mientras que la regresión logística puede asignar mayor peso a términos útiles para separar una clase de las demás.

4. Comparación con Naive Bayes

Modelo	Representación	Accuracy val.	F1 macro	F1 ponderado	Tiempo
Naive Bayes	BoW	0.8142	0.7389	0.8042	0.0159 s
Naive Bayes	TF-IDF	0.5792	0.3751	0.5023	0.0163 s
Regresión logística	BoW	0.8470	0.8278	0.8440	0.8765 s
Regresión logística	TF-IDF	0.7869	0.6488	0.7688	0.3511 s

En validación, Regresión Logística + BoW fue la mejor combinación. En prueba, el mayor accuracy fue de Regresión Logística + TF-IDF (0.8852), mientras que el mayor F1 macro fue de Regresión Logística + BoW (0.8517). Esto muestra que la elección depende de la métrica: BoW ofrece un mejor equilibrio entre categorías, mientras TF-IDF alcanza el mayor accuracy global.

Naive Bayes fue mucho más rápido de entrenar. Esto concuerda con su estimación aislada de $P(w|c)$ bajo independencia condicional. La regresión logística optimiza los pesos conjuntamente y, aunque es más costosa, logró mejores resultados en este corpus.

5. Análisis de errores

La confusión más frecuente de Regresión Logística + BoW fue Alianzas → Regulaciones, con 4 errores. Al revisar los cuatro documentos, aparecieron palabras con pesos positivos hacia Regulaciones como regulación, gobierno, ministerio, plataforma, Uber, ley, autoridad y mercado. Esto explica por qué noticias de alianzas empresariales podían parecer regulatorias para el modelo.

Al comparar con Naive Bayes, ambos modelos fallaron en los documentos 72, 694 y 806. Naive Bayes también confundió los documentos 452 y 613, que la regresión logística sí clasificó como Alianzas; en cambio, la regresión logística falló el documento 480, que Naive Bayes clasificó correctamente. Por tanto, comparten el tipo de error, pero no todos los documentos afectados.

Este resultado es consistente con la diferencia entre modelos: Naive Bayes combina señales según probabilidades de palabras individuales, mientras que la regresión logística puede ponderar conjuntamente características correlacionadas. Aun así, cuando un documento contiene vocabulario que pertenece naturalmente a ambas categorías, ambos modelos pueden coincidir en el error.

6. Análisis Final

1. ¿En qué se parecen y en qué difieren fundamentalmente Naive Bayes y regresión logística en la forma en que llegan a sus pesos?

Ambos trabajan sobre vectores de características y convierten las palabras en evidencia para decidir una clase. La diferencia principal es cómo obtienen esa evidencia: Naive Bayes estima $P(w|c)$ de forma separada y combina esas probabilidades bajo independencia condicional; la regresión logística aprende todos los pesos conjuntamente buscando separar las categorías. En nuestros resultados, la regresión logística alcanzó mejores F1 en validación y prueba, aunque Naive Bayes fue mucho más rápido.

2. ¿Encontró evidencia de esta diferencia en los pesos o en los errores? Dé un ejemplo concreto.

Sí. En Sostenibilidad, Naive Bayes colocó BBVA como la palabra con mayor $P(w|c)$, mientras regresión logística dio los mayores pesos a términos más específicos como sostenible, climático, verde y medioambiental. En errores, ambos modelos confundieron Alianzas - Regulaciones, pero corrigieron documentos distintos: la regresión logística acertó 452 y 613, donde Naive Bayes falló.

3. ¿Cuándo preferiría Naive Bayes y cuándo regresión logística?

Preferiría Naive Bayes con corpus pequeños, alta dispersión y necesidad de entrenamientos muy rápidos, especialmente cuando se necesita una línea base sencilla. También es útil cuando el costo computacional es una restricción importante. Preferiría regresión logística cuando haya suficientes datos y se busque mejor desempeño y pesos discriminativos interpretables. En este corpus, la ventaja de desempeño de regresión logística justifica su mayor tiempo de entrenamiento.

4. ¿Qué tanto aportan los modelos sobre la línea base de clase mayoritaria?

La línea base fue 0.2787 (27.87%), prediciendo siempre Macroeconomía. En prueba, Naive Bayes + BoW alcanzó 81.97%, Regresión Logística + BoW 87.43% y Regresión Logística + TF-IDF 88.52%. Por lo tanto, todos mejoran ampliamente la línea base; el mejor modelo supera la línea base en 60.65 puntos porcentuales de accuracy.

5. ¿Qué factores consideraría para producción y cambiaría la elección entre modelos?

Además del accuracy consideraría tiempo de inferencia, memoria, tamaño del modelo, interpretabilidad y facilidad de reentrenamiento. Naive Bayes tiene la ventaja de entrenar en alrededor de 0.02 s, mientras regresión logística tarda más, pero obtuvo el mejor desempeño. En este corpus mantendría regresión logística como opción principal, vigilando el desbalance de clases y reentrenando con datos nuevos para reducir el riesgo de degradación. Si la prioridad fuera minimizar al máximo el costo computacional, consideraría Naive Bayes como una alternativa.

Conclusión

En conjunto, la regresión logística mostró el mejor desempeño para este corpus, especialmente por su capacidad de aprender pesos discriminativos de manera conjunta. BoW presentó el mejor F1 macro en prueba, mientras TF-IDF alcanzó el mayor accuracy. Naive Bayes destacó por su velocidad de entrenamiento y mantuvo un desempeño claramente superior a la línea base, pero quedó por debajo de la regresión logística en las métricas principales.

Link de Repositorio :

https://github.com/Cynthiss/NLP/tree/main/Lab_4