

Laboratorio 5: Modelos de lenguaje

Reporte escrito – NLP – Cynthia Santos – 20230493

Este reporte resume la construcción y evaluación de modelos de lenguaje n-grama usando el texto de Don Quijote de la Mancha.

Resumen de resultados

Sección	Resultado principal
Preparación del corpus	9,577 oraciones; 7,661 entrenamiento, 958 validación y 958 prueba.
Vocabulario y OOV	21,150 palabras únicas en entrenamiento; 1,363 tokens OOV en prueba (2.94%).
Modelos n-grama	21,150 unigramas, 126,415 bigramas y 251,610 trigramas únicos.
Perplejidad	Mejor modelo en validación: unigrama con 550.59; prueba: 540.13.
Autocompletado	Unigrama sugiere palabras frecuentes; bigrama add-k usa la última palabra como contexto.

1. Preparación del corpus

El corpus se segmentó en oraciones y luego se tokenizó conservando el orden de las palabras. A cada oración se le agregaron los tokens especiales <s> y </s> para marcar inicio y fin.

Métrica	Valor
Oraciones totales	9,577
Entrenamiento	7,661 oraciones
Validación	958 oraciones
Prueba	958 oraciones
Vocabulario de entrenamiento	21,150 tokens únicos
Tokens OOV en prueba	1,363 de 46,397 tokens (2.94%)

Las palabras OOV muestran que el conjunto de entrenamiento no contiene todas las palabras que aparecen después en prueba. Esto se relaciona con la dispersión de datos, porque muchas palabras o combinaciones aparecen pocas veces o no aparecen en el corpus de entrenamiento.

2. Modelos n-grama

Se implementaron desde cero tres modelos basados en conteos: unigrama, bigrama y trigramas. Los conteos se almacenaron usando estructuras tipo diccionario, sin librerías especializadas de modelos de lenguaje.

Modelo	Conteos únicos	Ejemplo / resultado
Unigrama	21,150	$P(\text{"don"}) = 0.00564$
Bigrama	126,415	$P(\text{"quijote"} \mid \text{"don"}) = 0.82121$
Trigramas	251,610	$P(\text{"dijo"} \mid \text{"don quijote"}) = 0.00343$

Para la oración de validación “preguntó don quijote”, el trigramas obtuvo la probabilidad más alta, seguido por el bigrama y luego el unigrama. Esto ocurre porque el trigramas puede aprovechar mejor una secuencia común del corpus cuando esa combinación sí fue vista en entrenamiento.

Modelo	Probabilidad de la oración
Unigrama	$8.862615e-16$
Bigrama	$1.857352e-05$
Trigramas	$4.483713e-04$

3. Suavizado

Se aplicó suavizado de Laplace y add-k al modelo de bigramas. El objetivo fue evitar que un bigrama no visto tenga probabilidad cero.

Bigrama	Sin suavizado	Laplace	Add-k 0.5	Add-k 0.1
(don, quijote)	0.821211	0.075212	0.137770	0.412176
(quijote, computadora)	0.000000	0.000044	0.000041	0.000026

El suavizado dio una probabilidad pequeña al bigrama no visto. También redujo la probabilidad de un bigrama frecuente, porque reparte parte de la probabilidad hacia combinaciones que no aparecieron en entrenamiento.

4. Evaluación con perplejidad

La perplejidad se calculó sobre el conjunto de validación usando modelos con suavizado. Una menor perplejidad indica que el modelo predice mejor el texto evaluado.

Modelo	Perplejidad en validación
Unigrama	550.59
Bigrama	1731.84
Trigrama	9257.82

El mejor modelo fue el unigrama, con una perplejidad de 550.59 en validación y 540.13 en prueba. Aunque no usa contexto, fue más estable porque no depende de combinaciones largas que pueden no aparecer en entrenamiento.

k en bigrama add-k	Perplejidad en validación
1.00	1731.84
0.50	1241.18
0.10	659.96
0.01	411.12

En el bigrama, la perplejidad bajó cuando k fue más pequeño. Esto indica que un suavizado menos fuerte funcionó mejor, porque evita ceros sin cambiar demasiado los conteos originales.

5. Autocompletado

El mejor modelo por perplejidad fue el unigrama, pero para autocompletado también se probó el bigrama add-k porque usa la última palabra del fragmento como contexto.

Fragmento	Sugerencias
bien es verdad	que, lo, es, de, y
- no se	le, me, ha, lo, había
- muchos -	dijo, respondió, no, replicó, que
- conocía -	dijo, respondió, no, replicó, que
- nunca las	manos, que, cosas, armas, cuales

El unigrama sugiere palabras frecuentes como “que”, “de” o “y”. El bigrama produce sugerencias más relacionadas con el fragmento, aunque sigue siendo limitado porque solo mira una palabra anterior. Algunas sugerencias reflejan el estilo narrativo y antiguo de Don Quijote.

6. Análisis final

1. **¿Por qué la regla de la cadena de probabilidad, aunque exacta, no es utilizable directamente para estimar $P(\text{oración})$ con datos reales? Relacione su respuesta con los resultados de la sección 1 (vocabulario y OOV).**

La regla de la cadena usa todo el historial anterior de palabras, pero esos historiales largos casi nunca se repiten en un corpus real. En la sección 1 se observó un 2.94% de tokens OOV en prueba, lo que confirma que siempre aparecen palabras o combinaciones no vistas. Por eso, estimar $P(\text{oración})$ directamente con todo el contexto es muy difícil.

2. **Compare los resultados de perplejidad y de generación de texto entre unigrama, bigrama y trigramas. ¿Confirman el trade-off entre contexto y dispersión de datos?**

Sí lo confirman. El unigrama obtuvo la menor perplejidad porque es más fácil de estimar, aunque no usa contexto. El bigrama y el trigramas usan más información, pero dependen de combinaciones específicas que aparecen pocas veces o no aparecen. En el autocompletado, el bigrama fue más útil que el unigrama porque sí usa la última palabra como contexto, pero sigue siendo limitado.

3. **¿Qué efecto tuvo el suavizado sobre la perplejidad y sobre la calidad del texto generado? ¿Por qué es necesario incluso cuando el corpus de entrenamiento es grande?**

El suavizado evitó probabilidades cero y permitió evaluar combinaciones nuevas. También redujo un poco la probabilidad de combinaciones frecuentes porque reparte probabilidad hacia n-gramas no vistos. En el bigrama, un k pequeño funcionó mejor que Laplace. Es necesario incluso con corpus grandes porque ningún corpus contiene todas las palabras ni todas las combinaciones posibles.

4. **Si tuviera que elegir un valor de n para un sistema de autocompletado en producción, tomando en cuenta velocidad, memoria y calidad, ¿qué n elegiría y por qué?**

Elegiría un bigrama. Aunque el unigrama ganó en perplejidad, no es ideal para autocompletar porque no usa contexto. El bigrama ofrece un mejor equilibrio: usa la palabra anterior, es rápido y requiere menos memoria que un trigramas. No elegiría trigramas como primera opción porque puede sufrir más por combinaciones no vistas.

El laboratorio permitió observar cómo los modelos n-grama estiman probabilidades a partir de conteos. También mostró que más contexto no siempre mejora el resultado, especialmente cuando hay dispersión de datos. El suavizado fue necesario para manejar combinaciones no vistas, y el autocompletado evidenció que incluso un modelo simple puede generar sugerencias útiles, aunque limitadas.

Repositorio

- https://github.com/Cynthiss/NLP/tree/main/Lab_5