

## Laboratorio 6:

### Etiquetado gramatical y Reconocimiento de Entidades Nombradas

Cynthia Santos – 20230493

Este reporte resume la aplicación de etiquetado gramatical (POS Tagging) y reconocimiento de entidades nombradas (NER) sobre tres novelas clásicas utilizando spaCy.

#### Resumen de resultados

| Sección                   | Resultado principal                                                         |
|---------------------------|-----------------------------------------------------------------------------|
| Preparación de la muestra | 100 oraciones por libro para el análisis.                                   |
| POS Tagging               | Predominaron NOUN, VERB, PRON y PUNCT; se observaron palabras ambiguas.     |
| Tagsets                   | Alta coincidencia entre Penn Treebank y la anotación manual.                |
| NER                       | 517 entidades en Pride and Prejudice, 189 en Frankenstein y 205 en Dracula. |
| BIO                       | Se construyó la secuencia BIO para un fragmento de cinco oraciones.         |
| Evaluación                | Mejor desempeño en Pride and Prejudice (F1 Token=0.684; F1 Entidad=0.727).  |

#### 1. Preparación de la muestra

Cada novela fue segmentada en oraciones y tokenizada. Posteriormente se seleccionó una muestra aleatoria de 100 oraciones para trabajar durante el resto del laboratorio. Esta muestra permitió realizar el análisis manual de POS, NER y BIO.

#### 2. Etiquetado gramatical (POS)

El modelo asignó una categoría gramatical a cada token. Las categorías más frecuentes fueron NOUN, VERB, PRON y PUNCT. También se observaron palabras ambiguas como 'that' y 'well', cuya etiqueta cambió dependiendo del contexto.

| Resultado                | Descripción                                 |
|--------------------------|---------------------------------------------|
| Categorías predominantes | NOUN, VERB, PRON y PUNCT                    |
| Palabras ambiguas        | that, well y before                         |
| Comentario               | La categoría correcta depende del contexto. |
|                          |                                             |

### 3. Tagsets y anotación

Se comparó el tagset universal con Penn Treebank utilizando *Pride and Prejudice*. Penn Treebank proporciona etiquetas más específicas como VBD, PRP y JJ, mientras que el tagset universal utiliza categorías generales. La comparación manual mostró una alta coincidencia con el modelo.

| Tagset Universal | Penn Treebank   |
|------------------|-----------------|
| VERB             | VBD, VB, VBN... |
| PRON             | PRP, PRP\$      |
| ADJ              | JJ              |

### 4. Reconocimiento de entidades (NER)

El modelo detectó correctamente la mayoría de personajes y lugares principales.

| Libro                      | Entidades | Densidad/100 tokens |
|----------------------------|-----------|---------------------|
| <i>Pride and Prejudice</i> | 517       | 5.79                |
| <i>Frankenstein</i>        | 189       | 2.27                |
| <i>Dracula</i>             | 205       | 2.55                |

### 5. Esquema BIO

Se construyó manualmente una secuencia BIO para un fragmento de cinco oraciones consecutivas. La mayoría de los tokens fueron etiquetados como O y las entidades utilizaron etiquetas B e I.

### 6. Evaluación

| Libro                      | F1 Token | F1 Entidad |
|----------------------------|----------|------------|
| <i>Pride and Prejudice</i> | 0.684    | 0.727      |
| <i>Frankenstein</i>        | 0.333    | 0.471      |
| <i>Dracula</i>             | 0.462    | 0.444      |

*Pride and Prejudice* obtuvo el mejor desempeño, mientras que *Frankenstein* y *Dracula* presentaron mayor dificultad para el modelo.

### 7. Análisis final

#### ¿Qué diferencias de estilo puede inferir entre los 3 autores?

*Pride and Prejudice* presentó la mayor densidad de entidades (5.79 entidades por cada 100 tokens), lo que indica un mayor uso de nombres de personajes y lugares. En cambio, *Frankenstein* (2.27) y *Dracula* (2.55) mostraron una menor cantidad de entidades, lo que sugiere un estilo con más descripción y menos referencias constantes a nombres propios. Aunque la distribución de categorías gramaticales fue similar en los

tres libros, estas diferencias muestran que cada autor utiliza los personajes y escenarios de forma distinta.

### **¿Por qué la ambigüedad POS es similar al problema de un modelo n-grama?**

En ambos casos la decisión depende del contexto. El etiquetador POS utiliza las palabras cercanas para determinar la categoría gramatical correcta de una palabra, mientras que un modelo n-grama utiliza ese mismo contexto para predecir cuál es la siguiente palabra más probable. Por ello, ambos son problemas de predicción condicionada al contexto y no pueden resolverse observando únicamente una palabra de forma aislada.

### **¿Qué errores atribuiría a la diferencia de dominio?**

El tagger y el modelo de NER fueron entrenados con inglés contemporáneo, mientras que las tres novelas pertenecen al siglo XIX. Esto puede provocar errores al reconocer nombres propios, lugares o expresiones antiguas que aparecen con poca frecuencia en los datos de entrenamiento. Esta situación se relaciona con el problema de vocabulario fuera de dominio (OOV), ya que el modelo encuentra palabras o entidades que no conoce o que aparecen en un contexto diferente al utilizado durante su entrenamiento.

### **¿Qué métrica reportaría a un cliente?**

Reportaría la evaluación por **entidad completa**, ya que refleja si el modelo identificó correctamente toda la entidad, incluyendo su inicio, su final y su tipo. Aunque la evaluación por token es útil para analizar errores específicos, la evaluación por entidad completa representa mejor el desempeño del sistema en una aplicación real de reconocimiento de entidades.

## **Conclusión**

Los resultados muestran que las herramientas modernas de NLP funcionan adecuadamente sobre novelas clásicas, aunque el estilo del autor y la época de escritura influyen en su desempeño. *Pride and Prejudice* obtuvo los mejores resultados tanto en la detección de entidades como en la evaluación del modelo, mientras que *Frankenstein* y *Dracula* presentaron mayores desafíos debido a la presencia de nombres, lugares y expresiones menos comunes. En conjunto, el laboratorio permitió comprobar la importancia del contexto para tareas como el etiquetado gramatical y el reconocimiento de entidades, así como el impacto que tiene el dominio de entrenamiento en el rendimiento de los modelos.

## **Repositorio**

[https://github.com/Cynthiss/NLP/tree/main/Lab\\_6](https://github.com/Cynthiss/NLP/tree/main/Lab_6)